

Lab 01: Métodos no supervisados

Dylan Elizondo Alvarado (504610652)
Joseph Garcia Montero (402680547)
Rodrigo Ureña Castillo (118910482)
Mariana Ureña Padilla (119180324)

EIF420O – 2026

1. Introducción y objetivos

Se analiza el conjunto de datos proporcionado para el laboratorio, conservado en `data/ejemplo_analisis.cs`. Contiene 16 observaciones, cuatro variables numéricas (`edad`, `ingresos`, `visitas` y `satisfaccion`) y la categoría `segmento`. No se dispone de un diccionario que establezca moneda, período de visitas, escala de satisfacción o población de origen; por ello, se interpretan relaciones dentro de la muestra, sin atribuirles un contexto comercial no documentado.

El objetivo es caracterizar los datos mediante análisis exploratorio (EDA), comparar ACP, HAC, K-Means, t-SNE y UMAP, y seleccionar configuraciones justificadas por métricas y visualizaciones. La reducción dimensional y el agrupamiento responden preguntas distintas: representar información en pocos ejes no equivale a demostrar la existencia de grupos naturales.

1.1. Exploración de los datos

Las variables numéricas varían en escalas muy distintas, especialmente ingresos frente a satisfacción. Hay un faltante en ingresos (fila 6) y otro en satisfacción (fila 15), con numeración desde 1: dos celdas, en dos filas distintas. Cada variable afectada tiene 6.25 % de valores ausentes; no se eliminó ninguna observación. No hay filas completas duplicadas. La categoría `segmento` contiene Nuevo (6), Frecuente (6) y Ocasional (4). Se conserva para describir la entrada, pero se excluye de los modelos y no se utiliza como verdad de referencia.

Cuadro 1: Descriptivos originales, antes de imputar. DE: desviación estándar muestral.

Variable	Válidos	Media	Mediana	DE	Mín.	Máx.
edad	16	38.31	38.00	11.31	22.0	56.0
ingresos	15	1876.67	1800.00	798.95	850.0	3010.0
visitas	16	8.75	8.00	5.30	2.0	18.0
satisfaccion	15	7.82	7.70	1.01	6.2	9.3

Las seis correlaciones de Pearson, calculadas antes de imputar y con pares completos, están entre 0.9801 y 0.9942. La relación edad–ingresos es 0.9942; edad–visitas, 0.9842; edad–satisfacción, 0.9852; ingresos–visitas, 0.9882; ingresos–satisfacción, 0.9801; visitas–satisfacción, 0.9873. Son asociaciones descriptivas fuertes, no evidencia de causalidad. Se anticipa una dirección común dominante para ACP. Con la regla univariada de 1.5 veces el rango intercuartílico no se detectan valores atípicos numéricos; esto no descarta anomalías multivariadas.




Figura 1: Relaciones originales. El segundo panel omite la fila cuyo ingreso está ausente.

2. Fundamentos teóricos

2.1. Análisis exploratorio y preparación

EDA examina distribución, escala, faltantes y relaciones, combinando estadísticos y gráficos antes de imponer un modelo [1]. Permite justificar la preparación y detectar problemas que alterarían las distancias. La estandarización $z_{ij} = (x_{ij} - \mu_j)/\sigma_j$ evita que una variable domine solamente por sus unidades, aunque no elimina correlaciones ni vuelve equivalentes sus significados.

2.2. Análisis de componentes principales (ACP)

ACP representa los datos centrados mediante ejes ortogonales ordenados por varianza. Para una matriz preparada X , las puntuaciones son $T = XV$ y la varianza explicada por el componente j es $\lambda_j / \sum_\ell \lambda_\ell$. Conservar pocos componentes comprime información, pero puede perder señales de baja varianza [2, 3]. La implementación usa PCA de scikit-learn [9]. El framework exporta cargas $L = V \text{diag}(\sqrt{\lambda_j})$: no son los vectores propios sin escalar ni correlaciones exactas. El signo de un componente puede invertirse sin cambiar su representación.

2.3. K-Means

K-Means alterna asignación al centro más próximo y actualización de centroides para reducir

$$J = \sum_{g=1}^k \sum_{i \in C_g} \|x_i - \mu_g\|^2.$$

Su inercia mide compactación en el espacio utilizado. Requiere fijar k , puede alcanzar mínimos locales y es sensible a escala y valores extremos [4, 10]. Un k mayor suele reducir la inercia: su mínimo por sí solo no determina una partición útil.

2.4. Agrupamiento jerárquico aglomerativo (HAC)

HAC comienza con observaciones separadas y fusiona grupos hasta construir una jerarquía [5]. Los enlaces single, complete y average utilizan, respectivamente, la distancia mínima, máxima y promedio entre pares de puntos de grupos distintos; Ward minimiza el incremento de variabilidad intragrupo y se utiliza con distancia euclidiana [8]. El dendrograma registra las alturas de fusión; un corte produce una partición. Las fusiones no se deshacen, por lo que el enlace puede afectar el resultado.

2.5. t-SNE

t-SNE compara probabilidades de vecindad del espacio original y de la proyección; en el espacio reducido usa una distribución t de colas pesadas y minimiza una divergencia de Kullback–Leibler [6]. Perplexity controla el alcance efectivo de las vecindades y debe ser menor que el número de observaciones [11]. Es un método exploratorio no lineal: los ejes no representan variables originales y las separaciones visuales entre grupos no deben leerse como distancias globales preservadas.

2.6. UMAP

UMAP construye un grafo ponderado de vecindad y optimiza su representación en baja dimensión [7]. El número de vecinos regula el énfasis local frente a uno más amplio; `min_dist` controla cuán juntos pueden quedar los puntos en la representación [14]. Modificar estos parámetros puede cambiar la apariencia de los grupos, sin demostrar categorías reales. Se estudia como proyección, no como algoritmo de agrupamiento.

2.7. Criterios de evaluación

Silhouette contrasta distancia media dentro del grupo (a) y distancia media al grupo alternativo más cercano (b): $s = (b - a) / \max(a, b)$. Valores altos favorecen separación y cohesión; la media requiere entre 2 y $n - 1$ grupos [12]. Se calcula en las cuatro variables preparadas, no en las proyecciones.

Trustworthiness T_q , entre 0 y 1, penaliza vecinos que aparecen en la proyección sin ser vecinos adecuados en el espacio original [13]. Aquí se fija $q = 5$ para comparar proyecciones de las mismas 16 filas. Un valor alto indica preservación local, no garantiza conservación global, estabilidad o validez semántica de los grupos. Silhouette y trustworthiness no son métricas intercambiables.

Mapa conceptual: datos $\rightarrow$ EDA $\rightarrow$ imputación y escala $\rightarrow$ {ACP, K-Means, HAC, t-SNE, UMAP} $\rightarrow$ varianza / silhouette / trustworthiness $\rightarrow$ interpretación, comparación y selección.

3. Metodología reproducible

3.1. Integración y ambiente

Los experimentos se ejecutan con el paquete local `framework_ia`. La clase `Cluster`, en `framework_ia/modelos/no_supervisado/agrupamiento.py`, implementa los cinco métodos y comparte la matriz preparada mediante `PreprocesadorNoSupervisado`. El ejecutor `scripts/ejecutar_lab01.py` organiza los barridos y exporta evidencia.

La ejecución registrada usa Python 3.12.14, NumPy 2.5.3, pandas 3.0.6, SciPy 1.18.1, scikit-learn 1.9.1, umap-learn 0.5.12 y Numba 0.68.0. Se fija semilla 42 donde el método utiliza aleatoriedad; UMAP usa un trabajador. Las versiones y el hash SHA-256 de la entrada quedan en `resultados/configuracion.json`. Una semilla facilita repetir el experimento en ese ambiente, pero no prueba estabilidad ante otras semillas o versiones.

3.2. Preprocesamiento

Se seleccionan las cuatro variables numéricas y se mantienen las 16 filas. Los faltantes se imputan con la **mediana**: ingresos = 1800 y satisfacción = 7.7. Después se aplica StandardScaler, calculando medias y desviaciones poblacionales sobre los datos imputados. No se codifica segmento, no se descartan columnas constantes porque no las hay y la matriz final tiene dimensión 16×4 . El EDA utiliza datos originales; los modelos y métricas usan la matriz imputada y estandarizada. Esta distinción evita confundir promedios originales con centroides preparados.

3.3. Configuraciones y selección

La configuración base se refiere a la interfaz del framework utilizado, no a todos los valores predeterminados de las bibliotecas subyacentes.

Cuadro 2: Configuraciones base y variaciones evaluadas.

Método	Base	Variaciones
ACP	2 componentes	2, 3 y 4 componentes
K-Means	$k = 3$, 20 inicializaciones, 500 iteraciones máximas	$k = 2, \dots, 10$; demás parámetros fijos
HAC	Ward, $k = 3$, distancia euclidiana	Ward, average, complete y single; $k = 2, \dots, 10$
t-SNE	Perplexity 30, 1000 iteraciones; base operativa 5	5 y 15; 30 se omite por $30 \not\leq 16$
UMAP	15 vecinos, min_dist 0.1, dos dimensiones	Vecinos $\{5, 10, 15\}$ y min_dist $\{0.0, 0.1, 0.5\}$

ACP selecciona el menor número *evaluado* de componentes que alcanza 95% de varianza. K-Means y HAC seleccionan el mayor silhouette; en empate se prefiere menor k y, para HAC, orden alfabético del enlace. t-SNE y UMAP seleccionan el mayor T_5 ; se desempata por menor perplexity, o por menor número de vecinos y después menor min_dist. Estas reglas documentadas evitan escoger una figura solamente por su apariencia.

3.4. Evidencia conservada

Se generaron 41 CSV y dos JSON en **resultados**: EDA, matriz preparada, comparaciones, cargas y varianza ACP, proyecciones, asignaciones, centroides, perfiles y matrices de vinculación HAC. El resumen registra **estado: completado** y la única omisión es t-SNE con perplexity 30. Los CSV completos permiten verificar valores no redondeados. Las tablas y figuras de este documento incorporan una instantánea de esa ejecución; si cambia la entrada o la configuración,

deben actualizarse también aquí. Las instrucciones operativas de instalación y ejecución están separadas en `COMO_EJECUTAR.md`.

4. Resultados y análisis

4.1. ACP

Cuadro 3: Varianza explicada del ACP sobre cuatro variables preparadas.

Componente	Varianza (%)	Acumulada (%)
CP1	98.2950	98.2950
CP2	1.1479	99.4429
CP3	0.3439	99.7868
CP4	0.2132	100.0000

Cuadro 4: Cargas exportadas por el framework para ACP de dos componentes.

Variable	Carga CP1	Carga CP2
edad	1.0291	0.0257
ingresos	1.0179	0.1702
visitas	1.0250	-0.0851
satisfaccion	1.0237	-0.1099




Figura 2: Proyección ACP y varianza. Los colores identifican los grupos K-Means, no las categorías de segmento.

CP1 concentra 98.2950 % de la varianza y tiene cargas positivas similares en las cuatro variables: representa la dirección compartida de aumento de edad, ingresos, visitas y satisfacción en esta muestra. CP2 explica apenas 1.1479 %, con una carga positiva mayor en ingresos y negativas en visitas y satisfacción; distingue variaciones relativas que no siguen exactamente esa dirección común. Las cargas pueden superar 1 porque no son correlaciones: StandardScaler usa desviación poblacional y la varianza del PCA utiliza el divisor $n - 1$.

Se seleccionan **dos componentes**, que conservan 99.4429 %. Agregar CP3 gana solo 0.3439 puntos porcentuales y CP4 otros 0.2132. La selección equilibra compresión e interpretación bidimensional. CP1 por sí solo supera 95 %, pero una sola dimensión no fue parte del barrido y no se presenta como la configuración seleccionada. La observación 6 sobresale en CP2 (aproximadamente 0.6336): su ingreso imputado puede influir en esa desviación, por lo que no se clasifica como anomalía real sin revisar el dato faltante. Los colores muestran asignaciones K-Means calculadas en cuatro dimensiones; ACP no generó esas etiquetas.

4.2. K-Means

Cuadro 5: Comparación de K-Means. Configuración base: $k = 3$.

k	Inercia	Silhouette
2	14.8194	0.6261
3	5.8810	0.5828
4	3.8418	0.5334
5	2.1546	0.5029
6	1.4148	0.5046
7	1.1046	0.4270
8	0.8126	0.3819
9	0.6090	0.3434
10	0.4129	0.2827




Figura 3: Curvas de K-Means calculadas en la matriz de cuatro variables estandarizadas.

Cuadro 6: Perfiles medios en unidades originales para K-Means seleccionado.

Grupo	Filas	Edad	Ingresos	Visitas	Satisfacción
0	10	31.00	1312.22	5.20	7.12
1	6	50.50	2723.33	14.67	8.87

El máximo silhouette corresponde a $k = 2$, con 0.6261. La base $k = 3$ obtiene 0.5828 y reduce la inercia de 14.8194 a 5.8810 (aproximadamente 60.3 %). El codo hace razonable considerar tres grupos para una descripción más detallada, pero no supera al modelo de dos grupos en el criterio de separación elegido. Para $k = 10$ la inercia llega a 0.4129 y silhouette baja a 0.2827: compactar fragmentando la muestra no implica mejorar la separación.

Los grupos seleccionados contienen 10 y 6 observaciones. El grupo 1 presenta mayores promedios en todas las variables originales que el grupo 0. Son perfiles descriptivos de esta entrada; no se les atribuyen categorías comerciales nuevas. Los perfiles originales omiten cada faltante al calcular su media: en el grupo 0 los promedios de ingresos y satisfacción utilizan 9 valores, aunque su tamaño es 10. Los centroides preparados, en cambio, usan todas las filas después de imputar y no están expresados en las unidades de esta tabla.

No se forzó $k = 3$ para coincidir con las tres categorías de segmento: esa columna no intervino en el ajuste ni en la selección. Los resultados son internos a la muestra y no constituyen validación externa.

4.3. HAC

Cuadro 7: Silhouette para las 36 configuraciones HAC. En todas, $k_{\text{real}} = k$.

k	Ward	Average	Complete	Single
2	0.6261	0.6261	0.6261	0.6261
3	0.5744	0.5828	0.5744	0.5828
4	0.5447	0.4924	0.5447	0.4924
5	0.5029	0.4714	0.5029	0.4714
6	0.5046	0.5046	0.5046	0.4225
7	0.4558	0.4558	0.4039	0.3753
8	0.3572	0.3640	0.3572	0.4086
9	0.3180	0.3278	0.2973	0.3278
10	0.2581	0.2671	0.2581	0.2671




Figura 4: Dendrograma HAC average, derivado de `hac_linkage.csv`. Un corte ilustrativo a 2.5 produce los dos grupos seleccionados.

Los cuatro enlaces alcanzan el mismo máximo silhouette, 0.6261, con **dos grupos**. Se conserva **average**, $k = 2$ por la regla de desempate alfabética del ejecutor; no existe evidencia métrica de que average sea superior a Ward, complete o single en ese corte. La base Ward con tres grupos obtiene 0.5744. Para tres grupos, average y single mejoran a 0.5828, pero siguen debajo del máximo de dos grupos. En las 36 configuraciones el número efectivo de grupos coincide con el solicitado; se registra este dato porque un corte maxclust puede dar menos grupos cuando existen empates de alturas.

En el dendrograma average la penúltima fusión ocurre a 1.9637 y la última a 3.6397. Un corte entre esas alturas separa un conjunto de 6 observaciones (filas 7–12) y otro de 10 (filas 1–6 y 13–16). La partición coincide con K-Means seleccionado, aunque sus identificadores numéricos están intercambiados. Por tanto, los perfiles son los mismos y no es necesario reinterpretarlos como grupos diferentes. Esta concordancia entre dos procedimientos apoya la descripción dentro de la muestra, pero no demuestra estabilidad ni la existencia universal de dos clases.

Las alturas del dendrograma dependen del enlace y la escala preparada; no deben compararse como si fueran una misma magnitud entre Ward y average. Las diferencias para cortes más finos muestran que el enlace sí importa aunque todos coincidan en el corte de dos grupos.

4.4. t-SNE

Cuadro 8: Comparación t-SNE con cinco vecinos para trustworthiness.

Perplexity	T_5	Estado
5	0.992188	Evaluada y seleccionada
15	0.484375	Evaluada
30	—	Omitida: requiere menos de 16




Figura 5: Comparación t-SNE. Mismos colores K-Means en ambas proyecciones; las escalas de los paneles son independientes.

Se selecciona **perplexity 5**: preserva vecindades con $T_5 = 0.9922$, frente a 0.4844 con 15. La segunda configuración considera una vecindad muy amplia para 16 filas y, en esta ejecución, conserva peor los vecinos locales evaluados. El resultado no permite afirmar que perplexity 15 sea inadecuada para cualquier conjunto de datos.

La base 30 no puede ejecutarse válidamente y se documenta su omisión, en lugar de sustituirla silenciosamente. La base operativa 5 mantiene el análisis factible. Los colores K-Means sirven como referencia visual: no se vuelven a ajustar grupos sobre el plano t-SNE. La diferencia entre proyecciones respalda la necesidad de comparar hiperparámetros; separaciones o tamaños visuales no son medidas fiables de diferencias globales entre grupos. Se mantuvo una sola semilla y no se comprobó estabilidad al repetir el ajuste con otras.

4.5. UMAP

Cuadro 9: Trustworthiness de UMAP ($q = 5$). d representa min_dist .

Vecinos	$d = 0.0$	$d = 0.1$	$d = 0.5$
5	0.984375	0.987500	0.984375
10	0.987500	0.987500	0.984375
15	0.979688	0.967187	0.964063




Figura 6: UMAP seleccionado frente a la configuración base. Colores K-Means, escalas independientes.

Se selecciona **5 vecinos y min_dist 0.1**, con $T_5 = 0.9875$. Hay empate con 10 vecinos y min_dist 0.0 o 0.1; se eligen menos vecinos según la regla documentada. Para 5 vecinos, min_dist 0.0 y 0.5 obtienen 0.9844. La base 15/0.1 obtiene 0.9672; reducir vecinos mejora la preservación local evaluada en esta muestra.

La diferencia entre min_dist 0.0 y 0.1 no tiene una dirección universal: con 15 vecinos, 0.0 obtiene 0.9797, mientras que con 5 vecinos gana 0.1. Esto muestra interacción entre parámetros y evita tratar un valor como óptimo independiente del contexto. Con 15 vecinos se conecta una fracción muy grande de las 16 filas; el criterio T_5 evalúa una vecindad más local. Por ello, su selección no equivale a optimizar toda la geometría global.

El t-SNE seleccionado obtiene un T_5 ligeramente mayor (0.9922 frente a 0.9875), bajo la misma matriz y vecindad de evaluación. Es una diferencia descriptiva, no una prueba estadística de superioridad. No se evaluaron tiempos ni capacidad de generalización. Ninguno de los dos métodos reemplaza la explicación de las variables que ofrece ACP.

5. Conclusiones

El EDA identifica escalas heterogéneas, dos faltantes y fuerte asociación positiva entre las cuatro variables numéricas. La imputación por mediana y la estandarización permiten conservar 16 observaciones y comparar métodos sobre una misma matriz. La categoría segmento queda fuera del ajuste para mantener el carácter no supervisado.

ACP con dos componentes retiene 99.4429% y describe una dirección dominante común. K-Means con dos grupos y HAC average con dos grupos alcanzan silhouette 0.6261 y la misma partición; el empate de los cuatro enlaces HAC se resuelve por una convención reproducible, no por superioridad estadística. La alternativa de tres grupos aporta más detalle y menor inercia,

pero pierde en el criterio elegido. t-SNE con perplexity 5 y UMAP con 5 vecinos/min_dist 0.1 preservan bien los vecinos locales de esta ejecución.

Las conclusiones se restringen a una muestra pequeña, con unidades y población de origen no documentadas y dos imputaciones. Las métricas son internas y se evaluó una sola semilla; no hay prueba de estabilidad, validación externa ni inferencia causal. Un trabajo posterior podría comparar otras semillas y tratamientos de faltantes, y contrastar los grupos con información externa antes de utilizarlos para decisiones. La entrega conserva entrada, código y resultados completos, de modo que las selecciones pueden verificarse y repetirse.

Referencias

- [1] NIST/SEMATECH. *e-Handbook of Statistical Methods: Exploratory Data Analysis*. <https://www.itl.nist.gov/div898/handbook/eda/eda.htm>.
- [2] I. T. Jolliffe. *Principal Component Analysis*, segunda edición. Springer, 2002.
- [3] I. T. Jolliffe y J. Cadima. Principal component analysis: a review and recent developments. *Philosophical Transactions of the Royal Society A*, 374:20150202, 2016. <https://doi.org/10.1098/rsta.2015.0202>.
- [4] J. B. MacQueen. Some methods for classification and analysis of multivariate observations. *Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability*, vol. 1, pp. 281–297, 1967. <https://digicoll.lib.berkeley.edu/record/113015>.
- [5] F. Murtagh y P. Contreras. Algorithms for hierarchical clustering: an overview. *WIREs Data Mining and Knowledge Discovery*, 2(1):86–97, 2012. <https://doi.org/10.1002/widm.53>.
- [6] L. van der Maaten y G. Hinton. Visualizing data using t-SNE. *Journal of Machine Learning Research*, 9:2579–2605, 2008. <https://www.jmlr.org/papers/v9/vandermaaten08a.html>.
- [7] L. McInnes, J. Healy y J. Melville. UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction, 2018. <https://arxiv.org/abs/1802.03426>.
- [8] SciPy. *scipy.cluster.hierarchy.linkage*, documentación de referencia. <https://docs.scipy.org/doc/scipy/reference/generated/scipy.cluster.hierarchy.linkage.html>.
- [9] scikit-learn. *PCA*, documentación de referencia. <https://scikit-learn.org/stable/modules/generated/sklearn.decomposition.PCA.html>.
- [10] scikit-learn. *KMeans*, documentación de referencia. <https://scikit-learn.org/stable/modules/generated/sklearn.cluster.KMeans.html>.
- [11] scikit-learn. *TSNE*, documentación de referencia. <https://scikit-learn.org/stable/modules/generated/sklearn.manifold.TSNE.html>.
- [12] scikit-learn. *silhouette_score*, documentación de referencia. https://scikit-learn.org/stable/modules/generated/sklearn.metrics.silhouette_score.html.
- [13] scikit-learn. *trustworthiness*, documentación de referencia. <https://scikit-learn.org/stable/modules/generated/sklearn.manifold.trustworthiness.html>.
- [14] UMAP. *Basic UMAP Parameters*, documentación oficial. <https://umap-learn.readthedocs.io/en/latest/parameters.html>.